

SAE S4 : DATAMINING

Enzo SELVARATNAM & Alin PATA

Phase 1

Rapport EDA : Credit Card for Clustering

Lien vers le dataset : <https://www.kaggle.com/datasets/arjunbhasin2013/ccdata>



	CUST_ID	BALANCE	BALANCE_FREQUENCY	PURCHASES	ONEOFF_PURCHASES	INSTALLMENTS_PURCHASES	CASH_ADVANCE	PURCHASES_FREQUENCY
0	C10001	40.900749	0.818182	95.40	0.00	95.4	0.000000	0.166667
1	C10002	3202.467416	0.909091	0.00	0.00	0.0	6442.945483	0.000000
2	C10003	2495.148862	1.000000	773.17	773.17	0.0	0.000000	1.000000
3	C10004	1666.670542	0.636364	1499.00	1499.00	0.0	205.788017	0.083333
4	C10005	817.714335	1.000000	16.00	16.00	0.0	0.000000	0.083333

Partie 1 a) : Présentation du dataset

Ce dataset a été trouvé sur Kaggle et il nous présente les données comportementales de 8950 détenteurs de cartes de crédit actifs au cours des 6 derniers mois (lors de la création du dataset). Les données proviennent d'une banque commerciale anonymisée l'institution exacte n'est pas rendue publique pour des raisons de confidentialité.

Il s'agit d'un jeu de données financier sur des clients bancaires, composé de 17 variables quantitatives et 1 qualitative. Celles-ci décrivent précisément la manière dont les utilisateurs se servent de leur carte et gèrent leur compte bancaire. On y retrouve des indicateurs tel que:

- **Les habitudes de dépenses :** Le montant total des achats, la fréquence d'utilisation de la carte, et la distinction entre les achats ponctuels et les paiements en plusieurs fois.
- **La gestion du solde et du crédit :** Le solde restant sur le compte, la limite de crédit autorisée, et le recours aux retraits d'espèces à crédit).
- **Le comportement de remboursement :** Le montant des paiements effectués, les paiements minimums réalisés, et le pourcentage de fois où le solde est remboursé en total.

Cette base de données nous a intéressés par le fait qu'elle pourrait nous permettre de distinguer les comportements financiers. Les banques ont des départements data, on se met en situation si dans le futur on travaille dans ce secteur. Ce travail nous aiderait à comprendre comment cela marche.

L'objectif final est de transformer ces données en comportements types pour mieux comprendre la gestion financière chez le client et les classer selon leurs types.

Dictionnaire des variables :

Variable	Description	Variable	Description
CUST_ID	Identification du titulaire de la carte de crédit. (ex : C10001)	PURCHASES_INSTALLMENTS_FREQUENCY	Fréquence des achats effectués en plusieurs fois. (ex : 0.4)
BALANCE	Montant du solde restant sur le compte pour les achats. (ex : 1564.65)	CASH_ADVANCE_FREQUENCY	Fréquence à laquelle les retraits sont effectués. (ex : 0.0)
BALANCE_FREQUENCY	Fréquence de mise à jour du solde (score entre 0 et 1). (ex : 1.0)	CASH_ADVANCE_TRX	Nombre de retraits. (ex : 2)
PURCHASES	Montant total des achats effectués depuis le compte. (ex : 1003.32)	PURCHASES_TRX	Nombre total de transactions d'achats effectuées. (ex : 15)
ONEOFF_PURCHASES	Montant maximum des achats effectués en une seule fois. (ex : 450.00)	CREDIT_LIMIT	Limite de crédit accordée à l'utilisateur. (ex : 3000.00)
INSTALLMENTS_PURCHASES	Montant des achats effectués en plusieurs fois. (ex : 120.00)	PAYMENTS	Montant des paiements effectués par l'utilisateur. (ex : 850.00)
CASH_ADVANCE	Avance de fonds (retrait d'espèces) effectuée. (ex : 200.00)	MINIMUM_PAYMENTS	Montant minimum des paiements effectués par l'utilisateur. (ex : 250.00)
PURCHASES_FREQUENCY	Fréquence à laquelle les achats sont effectués (0 à 1). (ex : 0.5)	PRCFULLPAYMENT	Pourcentage de paiements complets effectués. (ex : 0.25)
ONEOFF_PURCHASES_FREQUENCY	Fréquence des achats effectués en une seule fois. (ex : 0.1)	TENURE	Durée du service de carte de crédit (ancienneté en mois). (ex : 12)

Partie 1 b) : Nettoyage des Données

Pour faciliter la compréhension de notre étude, nous avons commencé par traduire l'ensemble des variables en français (*voir annexe*). Nous avons également retiré IDENTIFIANT, elle n'apporte aucune information pour notre étude.

On a ensuite analysé les lignes du dataset et on a remarqué qu'il y avait 2 variables qui possédaient des valeurs manquantes.

- Pour la variable LIMITE_CREDIT, nous avons observé une valeur manquante et avons décidé de supprimer la ligne correspondante.
- Pour MIN_PAIEMENT on a vu 313 valeurs manquantes.
On a fouillé la variable et comparé à la variable MONTANT_PAIEMENT on suppose que $MONTANT_PAIEMENT > MIN_PAIEMENT$. Après avoir filtré ces 2 variables on a vu que 2364 clients ont effectué un paiement inférieur au paiement minimum ce qui est incohérent.

Nous avons réalisé un test qui permet de corriger ces anomalies.

Si le client n'a effectué aucun paiement, on estime que son paiement minimum était de 0.

Si le client a payé une somme inférieure à la moyenne globale, nous avons remplacé la valeur manquante dans la variable du paiement minimum par le montant du paiement.

Dans les autres cas, nous avons remplacé la donnée manquante par la moyenne globale des montants payés.


Maintenant que nos données sont prêtes, on va regarder chaque colonne de plus près pour voir comment se répartissent nos données/clients, en utilisant des statistiques de dimension 1 comme la moyenne et graphiques pour fouiller les données.

Partie 2 a) : Analyse en dimension 1

Avant d'analyser les variables qui nous semblent les plus importantes, on a décidé de faire un histogramme sur chacune des variables pour étudier leurs comportements.

Répartition des clients par variables

Remarque : Pour plus de lisibilité dans les graphiques nous avons décidé d'enlever les clients supérieurs au quantile 0.95.



Nous observons la répartition de la clientèle standard. Plusieurs constats sont visibles.

Les variables financières comme le solde ou le montant des achats présentent une distribution inégale :

la majorité des clients ont des montants faibles à moyens, et leur nombre diminue à mesure que les montants augmentent.

La limite de crédit montre une structure particulière avec plusieurs pics (autour de 1500, 3000 ou 4000). Cela reflète les paliers utilisés par les banques pour attribuer les plafonds.

La fréquence d'achat révèle deux comportements opposés, certains clients utilisent très peu leur carte, alors que d'autres s'en servent très régulièrement.

Enfin, certaines variables sont très homogènes. La durée de la carte est de majoritairement de 12 mois, et le pourcentage de paiement complet est souvent proche de zéro, indiquant que la plupart des clients remboursent progressivement leur solde.

Pour la suite, il sera donc très intéressant de se focaliser sur ces variables financières (MONTANT_SOLDE, MONTANT_TOTAL_ACHATS...) pour voir comment elles se répartissent plus en détail.

Réalisons maintenant une analyse statistique du solde et du montant total des achats réalisés par les clients :

	Minimum	Maximum	Moyenne	Médiane	Variance
MONTANT_SOLDE	0.0	19043.14	1564.65	873.68	4332992.02
MONTANT_TOTAL_ACHATS	0.0	49039.57	1003.32	361.49	4565605.90

Les résultats obtenus confirment mathématiquement ce que nos graphiques laissaient deviner : les comportements de nos clients sont très inégaux. Pour nos deux variables, on observe des valeurs maximales très élevées par rapport aux montants moyens. Par exemple, le montant total des achats peut atteindre 49 039\$, alors que la moyenne se situe autour de 1003,32\$.

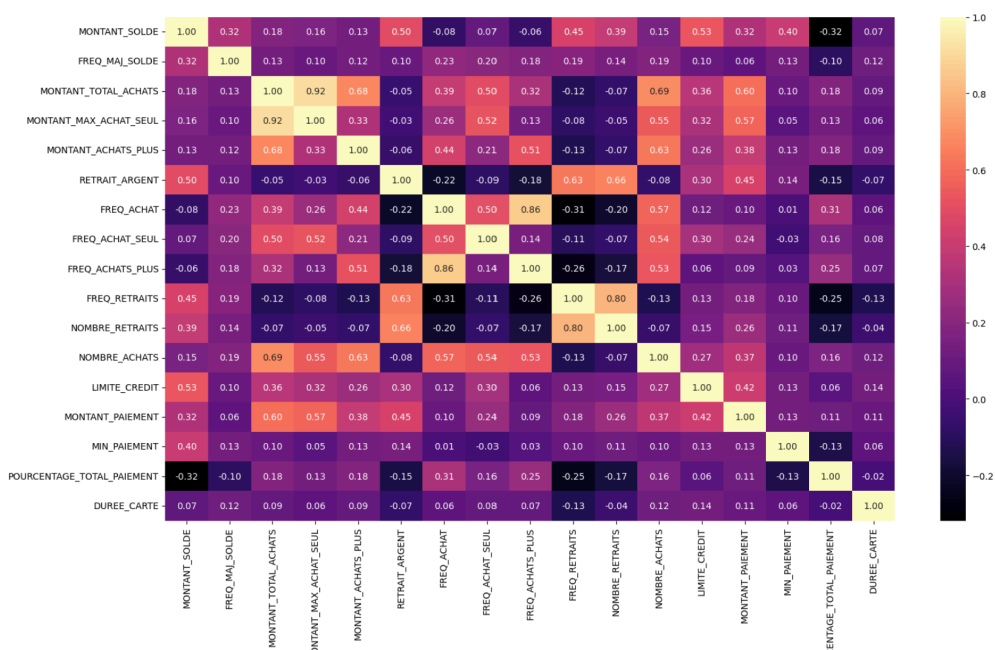
Cet écart important s'explique par la présence d'une minorité de clients aux montants très élevés qui tirent les valeurs vers le haut. De plus, la variance, qui dépasse les 4 millions pour les deux variables, montre que la dispersion est très importante entre un client classique et certains cas beaucoup plus extrêmes.

Partie 2 b) : Analyse en dimension 2

Pour déterminer quelles variables choisir pour notre étude afin de réaliser une classification par clusters, il est nécessaire d'observer quelles variables sont corrélées entre elles.

Pour cela, nous avons réalisé une matrice de corrélation entre toutes les variables :


On sait que la corrélation est forte entre deux variables lorsque le coefficient se rapproche de 1 et -1.



On peut voir dans cette matrice qu'il n'y a pas de variables avec de fortes corrélations négatives mais seulement positives. On distingue des variables fortement corrélées tel que le MONTANT_MAX_ACHATS et le MONTANT_MAX_ACHAT_SEUL. avec 0,92.

Ce qui indique une très forte corrélation (cela est logique car les deux variables sont similaires)

Regardons maintenant le nuage de points entre les variables les plus corrélées :



Réalisons maintenant la covariance entre ces différentes variables :

Covariance entre MONTANT_TOTAL_ACHATS et MONTANT_MAX_ACHAT_SEUL : 712521.9959008779

Covariance entre MONTANT_TOTAL_ACHATS et NOMBRE_ACHATS : 11546.345394964523

Covariance entre MONTANT_TOTAL_ACHATS et MONTANT_ACHATS_PLUS : 338780.96874944796

Covariance entre MONTANT_ACHATS_PLUS et NOMBRE_ACHATS : 4913.52712808053

Covariance entre MONTANT_TOTAL_ACHATS et MONTANT_PAIEMENT : 645504.8774033578

On constate que pour toutes les variables choisies, elles ont une covariance positive très élevée ce qui signifie que si une variable a tendance à croître l'autre suivra. Donc notre test de covariance indique une forte croissance entre nos variables.

Partie 3 : Classification

Ensuite pour pouvoir réaliser une classification il faut réduire au maximum les outiliers en les standardisant et en les normalisant afin d'enlever au maximum les valeurs aberrantes.



	MONTANT_SOLDE	FREQ_MAJ_SOLDE	MONTANT_TOTAL_ACHATS	MONTANT_MAX_ACHAT_SEUL
0	-0.809652	-0.334911	-0.641448	-0.543505
1	1.273272	0.091127	-0.734487	-0.543505
2	0.807271	0.517164	0.019551	0.430864
3	0.261448	-1.186986	0.727420	1.345575
4	-0.297867	0.517164	-0.718883	-0.523341

On a maintenant une base normalisée et on peut commencer la classification de 2 variables.

Pour notre classification on a choisi les variables MONTANT SOLDE et MONTANT_TOTAL ACHATS.

On a d'abord réalisé un dendrogramme afin de voir combien de clusters on doit choisir pour une classification optimale. (On a utilisé l'algorithme des CAH pour le dendrogramme et Kmeans pour le nuage de points)

On voit qu'il y a 3 groupes distincts sur le graphique on peut donc en déduire qu'il serait préférable de choisir 3 clusters.



On a donc réalisé le nuage des points cette fois-ci avec les clusters représentés et on peut voir que les 3 groupes se distinguent bien.

Kmeans

	MONTANT_TOTAL_ACHATS_MOYEN	MONTANT_SOLDE_MOYEN	NB_INDIVIDUS
cluster			
0	-0.332542	-0.401930	5277
1	-0.263592	1.841953	1158
2	2.062126	-0.012010	999

La classification basée sur le montant total des achats et le solde du compte met en évidence trois profils de clients.

Un premier groupe majoritaire (5 277 individus) correspond à des utilisateurs peu actifs avec des dépenses et un solde faibles.

Un deuxième groupe de 1 158 individus regroupe des clients présentant un niveau d'endettement très élevé (moyenne de 1.84) malgré des achats relativement modérés.

Enfin, un troisième groupe de 999 individus correspond à des utilisateurs intensifs de la carte de crédit qui réalisent des achats élevés tout en maintenant un solde relativement maîtrisé, proche de zéro.

Partie 4 : Choix de la problématique

Au vu de notre analyse exploratoire et de notre première classification, la segmentation met en évidence trois profils de clients bien distincts. Nous avons identifié des utilisateurs peu actifs, un groupe présentant un niveau d'endettement élevé, ainsi que des utilisateurs intensifs de la carte de crédit.

Ces différences entre les clients soulèvent la problématique suivante :

Comment la banque peut-elle adapter ses stratégies notamment la gestion des risques en fonction des profils de consommation et d'endettement de ses clients ?

Pour répondre à cette problématique, la prochaine étape de notre étude s'appuiera sur des méthodes d'analyse multidimensionnelle plus poussées.

Le passage à une classification en dimension supérieure ($N > 2$), couplée à une Analyse en Composantes Principales et à des modèles de régression, nous permettra de confirmer ces profils.

Annexe :

Variables renommées

```
# Après avoir défini Les variables on nettoie Le dataset
# On renomme Les variables
data = data.rename(columns={"CUST_ID" : "IDENTIFIANT",
                             "BALANCE" : "MONTANT_SOLDE",
                             "BALANCE_FREQUENCY" : "FREQ_MAJ_SOLDE",
                             "PURCHASES" : "MONTANT_TOTAL_ACHATS",
                             "ONEOFF_PURCHASES" : "MONTANT_MAX_ACHAT_SEUL",
                             "INSTALLMENTS_PURCHASES" : "MONTANT_ACHATS_PLUS",
                             "CASH_ADVANCE" : "RETRAIT_ARGENT",
                             "PURCHASES_FREQUENCY" : "FREQ_ACHAT",
                             "ONEOFF_PURCHASES_FREQUENCY" : "FREQ_ACHAT_SEUL",
                             "PURCHASES_INSTALLMENTS_FREQUENCY" : "FREQ_ACHATS_PLUS",
                             "CASH_ADVANCE_FREQUENCY" : "FREQ_RETRAITS",
                             "CASH_ADVANCE_TRX" : "NOMBRE_RETRAITS",
                             "PURCHASES_TRX" : "NOMBRE_ACHATS",
                             "CREDIT_LIMIT" : "LIMITE_CREDIT",
                             "PAYMENTS" : "MONTANT_PAIEMENT",
                             "MINIMUM_PAYMENTS" : "MIN_PAIEMENT",
                             "PRC_FULL_PAYMENT" : "POURCENTAGE_TOTAL_PAIEMENT",
                             "TENURE" : "DUREE_CARTE"
                            })
```